

“知界学伴”参赛方案

一、项目定位

作品名称：知界学伴 (KnowBound)

副标题：基于概念图谱与角色隔离记忆的可信误区诊断智能体

建议赛道：赛道一——AI+高等教育 / AI+教学

首个试点课程：《数据结构》

关键词：概念误区诊断、智能学伴、角色隔离记忆、概念图谱、隐私保护

一句话介绍：

知界学伴不是替学生回答问题，而是识别学生“为什么会错”，通过递进式提示帮助其自主纠错，并以角色隔离、授权访问和可验证遗忘机制安全管理长期学习记忆。

之所以优先选择赛道一，而不是赛道四，是因为“学习效果改善”比单纯展示记忆安全更容易形成完整教育故事。角色隔离记忆则作为作品最有辨识度的技术创新。

二、需要解决的真实问题

1. 普通大模型容易直接给答案

学生提交一道错题后，通用 AI 往往直接生成完整解法。短期看似解决问题，实际没有识别学生是概念不清、方法错误还是计算失误，容易形成依赖。

2. 教师无法及时发现共性误区

教师通常只能通过作业和考试结果看到“哪些题错得多”，很难快速判断背后的共同知识缺口，更难为不同学生提供个性化指导。

3. 长期记忆存在隐私和串号风险

学习助手如果长期记录学生的成绩、薄弱点、对话和学习习惯，可能发生：

- 不同学生之间的记忆混淆；
- 学生读取教师内部信息；
- 助教越权查看私人学习记录；
- 学生退课后数据仍被继续使用；
- 错误诊断被永久保存并反复强化。

4. AI教学成效难以验证

许多教育智能体只能展示“可以对话”，缺少前后测、迁移测试、诊断准确率和教师工作量等可核查数据。

三、目标用户

学生

获得针对自己认知过程的诊断和提示，而不是直接抄答案；能够查看、纠正和删除系统保存的个人学习记忆。

教师

查看班级匿名化误区分布，了解哪些知识点需要重新讲解，但不能浏览学生私人对话。

助教

在教师授权范围内处理答疑任务，仅能访问与当前课程、当前任务有关的信息。

四、核心使用场景

以《数据结构》中的“二叉树遍历”为例。

学生提交了一份错误答案，系统不直接显示正确代码，而是进行如下处理：

1. 识别错误发生在递归终止条件；
2. 将错误关联至概念图谱中的“递归调用栈”和“空节点处理”；
3. 查询该学生在当前课程中的历史误区；
4. 判断学生之前也曾在链表递归中遗漏终止条件；
5. 给出第一级提示：“递归函数在什么情况下应该停止？”
6. 如果学生仍无法作答，再逐级增加提示；
7. 学生完成纠错后，让其用自己的话解释原因；
8. 系统验证理解程度，并建议保存一条学习记忆；
9. 学生确认后，记录“递归终止条件理解不足”及其掌握状态；
10. 教师端只看到“班级中有 37% 的学生在递归终止条件上存在困难”，看不到具体学生对话。

五、核心功能设计

1. 概念误区诊断

系统将学生错误划分为四类：

- 概念性错误：不理解知识定义或关系；
- 策略性错误：知识点掌握，但选择了错误的方法；
- 程序性错误：步骤、代码或计算过程有误；
- 表达性错误：结论基本正确，但论证不完整。

诊断结果包含：

- 错误类型；
- 涉及的核心概念；

- 可能缺失的先修知识；
- 判断依据；
- 诊断置信度；
- 建议的下一步干预方式。

当置信度不足时，系统不强行下结论，而是追加一道诊断问题。

2. 课程概念图谱

首个版本只建设《数据结构》概念图谱，包含：

- 线性表；
- 栈与队列；
- 树与二叉树；
- 图；
- 查找；
- 排序；
- 时间与空间复杂度。

节点之间标注“先修关系”“容易混淆”“方法依赖”和“典型错误”等关系。

例如：

递归调用 → 依赖 → 调用栈
二叉树遍历 → 依赖 → 递归终止条件
BFS → 容易混淆 → DFS

图谱不追求规模，而追求每个节点都有教师审核过的误区和诊断问题。

3. 递进式提示阶梯

系统默认不直接给出最终答案，而是采用四级提示：

1. **反思提示：** 引导学生重新观察问题；
2. **概念提示：** 指出可能涉及的知识点；
3. **步骤提示：** 提供局部推导或伪代码；
4. **完整解析：** 在学生多次尝试或明确请求后提供。

系统记录学生在哪一级提示下完成纠错，用于估计其实际掌握程度。

4. 个人学习记忆

只保存对后续学习确有价值的信息，包括：

- 已掌握和未掌握的概念；
- 高频误区；
- 有效的提示方式；
- 最近一次验证结果；
- 记忆来源、置信度和有效期。

不默认保存完整聊天记录，也不保存与教学无关的个人信息。

每次写入长期记忆前，系统展示：

系统建议记住：“你容易遗漏递归终止条件。”

来源：二叉树遍历练习

有效期：30天

是否保存？

学生可以选择保存、修改或拒绝。

5. 角色隔离与可验证遗忘

每条记忆都带有以下边界：

学校 / 课程 / 用户 / 角色 / 任务 / 数据类型

系统在检索前和生成回答前分别进行一次权限检查，未经授权的数据不会进入大模型上下文。

主要机制包括：

- 学生只能访问自己的学习记忆；
- 教师只能看到匿名化班级统计；
- 助教只能访问被分配的任务；
- 不同课程的记忆默认不互通；
- 删除记忆时同步清理数据库、向量索引和缓存；
- 删除完成后执行反向查询，生成“遗忘验证结果”；
- 所有访问和修改操作进入审计日志。

为避免教师通过小样本统计推断学生身份，人数少于5人的统计分组不予展示。

6. 教师误区驾驶舱

教师端展示：

- 班级知识掌握热力图；
- 高频误区排行；
- 误区随时间的变化；
- 不同题目对应的错误根因；
- 推荐复讲的概念；
- 学生使用不同等级提示后的纠错率。

教师可以审核、修改系统总结的误区，并把典型问题加入下一轮教学内容。

六、系统工作流程

教师上传课程资料与典型误区

↓

建立课程知识库和概念图谱



七、技术架构

系统可以分成六个相对独立的模块。

1. 学习交互层

提供学生、教师和助教三类界面，包括答题、诊断反馈、记忆管理和班级分析。

2. 教学诊断引擎

负责分析学生答案、定位错误、生成诊断问题并控制提示等级。

3. 课程知识层

由课程资料库、题库、教师标注的典型误区和概念图谱组成，为诊断提供可靠依据。

4. 记忆管理层

负责记忆的提取、分类、授权、更新、过期、纠正和删除。

5. 权限与安全层

根据用户身份、课程、角色和任务执行访问控制，同时记录安全审计日志。

6. 模型服务层

统一调用大语言模型、嵌入模型和重排模型。所有模型输出必须经过结构校验和教学安全检查。

首个版本不需要训练大模型，重点是概念图谱、诊断流程和安全记忆机制。

八、异常与安全处理

异常情况	系统处理
诊断置信度不足	明确表示不确定，并追加诊断问题
课程资料中没有依据	不生成确定结论，提交教师复核
学生要求读取他人信息	权限层拒绝并记录审计日志
提示注入攻击	隔离用户输入，禁止其修改系统权限
新旧记忆互相冲突	保留来源和版本，由学生或教师确认
学生删除记忆	清理数据库、向量索引和缓存并验证
小样本可能暴露身份	少于5人的统计数据不展示
大模型直接泄露答案	输出检查器降低提示等级或重新生成

九、三个可选择的技术路线

路线A：教育效果优先，安全记忆增强——推荐

以误区诊断和学习效果为主线，角色隔离记忆作为技术创新。

优势是最符合赛道一，容易讲清教育价值，也能通过小规模试点形成成效数据。

路线B：记忆安全优先，教育场景验证

申报赛道四“基于角色隔离的记忆管理”，把教学系统作为记忆框架的应用案例。

优势是命题匹配度高；缺点是需要更完整的攻击测试、权限模型和删除验证，评委会更关注底层安全技术。

路线C：同时突出两个方向

误区诊断和记忆管理各占一半。

不推荐。这样容易导致教育评委觉得系统过于技术化，产业评委又觉得记忆机制不够深入。

十、实验与成效验证

- 建议设计三组对照：
- A组：普通大模型直接问答；
 - B组：具备课程知识库，但没有误区诊断和长期记忆；
 - C组：完整的知界学伴。

教育效果指标

指标	测量方法	目标值
误区诊断准确率	与教师标注结果比较	≥80%
同类题纠错率	学习后立即测试	提升15%以上
知识迁移正确率	使用不同表述的新题测试	提升10%以上
答案直接泄露率	统计过早提供完整答案的比例	≤5%
教师分析时间	人工分析与系统辅助对比	降低50%
学生满意度	五级量表问卷	≥4.0

安全效果指标

建立不少于100条攻击测试，包括：

- 读取其他学生的薄弱知识点；
- 冒充教师；
- 跨课程调用记忆；
- 通过提示注入要求忽略权限；
- 删除后重新询问已删除信息。

目标：

- 跨角色越权成功率：0；
- 跨学生记忆串用率：0；
- 删除验证通过率：100%；
- 敏感信息意外进入模型上下文的比例：0。

这些是目标值，最终材料必须同时披露真实结果、样本规模和实验限制。

十一、最小可行版本

在提交时间有限的情况下，首版只做：

- 一门课程：《数据结构》；
- 三类角色：教师、助教、学生；
- 文本题和代码片段，不做语音与视频；
- 30 ~ 50个核心概念；
- 50 ~ 100个教师标注误区案例；
- 四级提示；
- 个人记忆查看、纠正和删除；
- 教师匿名误区热力图；

- 一套越权攻击测试。

暂时不做：

- 全校课程平台；
- 自动批改所有类型作业；
- 摄像头情绪识别；
- 自动训练专属大模型；
- 复杂多智能体协作；
- 自动替教师生成完整教案。

控制范围会让核心功能更稳定，也更容易产出可信实验数据。

十二、项目进度建议

日期	主要任务
10月1日—3日	确定课程、指导教师、典型题目和误区体系
10月4日—8日	完成概念图谱、知识库和基础交互原型
10月9日—13日	完成误区诊断、提示阶梯和结果结构化
10月14日—17日	完成角色隔离记忆、授权、删除与审计
10月18日—21日	学生试用、对照实验和安全攻击测试
10月22日—23日	修复问题、整理数据、制作统计图
10月24日	完成文档、演示视频和支撑材料
10月25日	最终检查并提交

报名必须在10月10日前完成。

十三、团队分工

五人团队可以这样安排：

1. **产品与教学负责人：** 对接教师，设计概念图谱、误区体系和试点；
2. **AI负责人：** 诊断流程、知识检索和提示生成；
3. **后端负责人：** 用户、课程、记忆和权限服务；
4. **前端负责人：** 学生端、教师端和数据展示；
5. **测试与材料负责人：** 安全测试、实验统计、文档和视频。

指导教师主要负责审核误区分类、测试题和实验结论。

十四、十分钟演示视频结构

0—2分钟：问题与方案

展示普通AI直接给答案、教师无法看到误区、学习记录存在隐私风险。

2—5分钟：学生学习闭环

演示一道错误题目：

- 系统定位误区；
- 给出递进式提示；
- 学生完成纠错；
- 系统验证理解；
- 学生确认保存学习记忆。

5—7分钟：安全记忆

演示：

- 另一个学生试图读取该记忆；
- 助教尝试越权；
- 提示注入攻击；
- 学生删除记忆并完成遗忘验证。

7—8分钟：教师驾驶舱

展示匿名误区热力图、教学建议和纠错率。

8—10分钟：实验结果与推广

展示三组对照实验、安全测试结果、教师和学生反馈，以及迁移至其他课程的方法。

十五、与评审标准的对应关系

评审维度	对应内容
场景适配性 20分	真实课程、真实错题、教师和学生试点
技术规范性 25分	概念图谱、权限隔离、人工复核、数据审计、可验证遗忘
创新优化性 20分	从答案生成转向误区诊断，将安全记忆引入智能学伴
实施显著性 25分	前后测、对照实验、教师节省时间、安全攻击测试
推广适配性 10分	课程知识层可替换，核心诊断与记忆框架可以复用

十六、主要风险

- **没有真实教师参与：** 诊断标签缺乏可信度，实施显著性会明显减分。
 - **功能做得过多：** 应优先保证诊断闭环和记忆安全，而不是增加炫技功能。
 - **试点样本太少：** 可以诚实说明探索性试点性质，同时增加专家标注测试集。
 - **AI诊断不稳定：** 采用结构化输出、概念范围约束和低置信度人工复核。
 - **隐私口号化：** 必须真正展示越权失败、审计记录和删除验证。
 - **伪造成效数据：** 所有数字保留原始记录和计算方法，目标值不能写成实际结果。
-

十七、300字作品简介草案

知界学伴是一款面向高校课程学习的可信误区诊断智能体。针对通用大模型直接生成答案、难以识别学生认知根因，以及长期学习记忆可能发生串用和隐私泄露等问题，作品构建课程概念图谱，对学生解题过程进行概念性、策略性、程序性和表达性错误诊断，并通过递进式提示引导学生自主纠错。系统设置学生、教师、助教角色边界，对学习记忆进行分区存储、授权检索、用户确认、纠正和可验证遗忘；教师仅获取匿名化班级误区统计。作品以《数据结构》课程为试点，通过前后测、迁移测试、教师标注和越权攻击测试，验证学习效果、诊断准确性与记忆安全性，并可通过替换课程知识层推广至其他高校课程。

这版方案的核心取舍是：**赛道一为主、误区诊断为产品价值、角色隔离记忆为技术壁垒、《数据结构》为首个试点。**

你是否确认按这个主方向继续——即“赛道一 + 知界学伴 + 《数据结构》试点”？